UnB/ENE0154 - Inteligencia Computacional - 2025.2 - Prof. Adolfo Bauchspiess
Introdução ao Controle Inteligente Numérico - 28/09/2025

Identificação de Sistemas Lineares com RNA

Washington Marinho dos Santos *

* *170072274, Engenharia Mecatrônica UnB, 170072274@aluno.unb.br*

Abstract: This project addresses the use of an adaptive algorithm with an ADALINE (Adaptive Linear Neuron) network for the identification of a discrete-time linear dynamic system. Specifically, a second-order IIR (Infinite Impulse Response) system, whose dynamics change at a predefined time instant, is approximated by an adaptive FIR (Finite Impulse Response) filter. The implementation was carried out in Python, taking advantage of concepts of digital control and adaptive filtering. The results clearly show the effectiveness of the adaptive approach: the filter output successfully tracks the system output, adapting its synaptic weights in real time to the abrupt change in plant dynamics. In contrast, a globally optimized solution (using the pseudo-inverse method) fails to model the time-varying nature of the system. The study validates the effectiveness of ADALINE as a powerful tool for system modeling and identification. ADALINE as a powerful tool for modeling and identifying systems.

Resumo: Esse projeto aborda a utilização de um algoritmo adaptativo com uma rede ADALINE (Adaptive Linear Neuron) para a identificação de um sistema dinâmico linear de tempo discreto. Especificamente, um sistema IIR (Infinite Impulse Response) de segunda ordem, cuja dinâmica muda num instante de tempo predefinido, é aproximado por um filtro FIR (Finite Impulse Response) adaptativo. A implementação foi realizada em Python, aproveitando conceitos de controle digital e filtragem adaptativa. Os resultados mostram claramente a eficácia da abordagem adaptativa: a saída do filtro acompanha com sucesso a saída do sistema, adaptando os seus pesos sinápticos em tempo real à mudança abrupta na dinâmica da planta. Em contrapartida, uma solução otimizada globalmente (através do método pseudo-inverso ou Newlind) não consegue modelar a natureza variável no tempo do sistema. O estudo valida a eficácia da ADALINE como uma ferramenta poderosa para modelagem e identificação de sistemas.

Keywords: System Identification; Artificial Neural Networks; ADALINE; LMS Algorithm; Adaptive Filters; Time-Varying Systems; Intelligent Control; Python; Keras.

Palavras-chaves: Identificação de Sistemas; Redes Neurais Artificiais; ADALINE; Algoritmo LMS; Filtros Adaptativos; Sistemas Variantes no Tempo; Controle Inteligente; Python; Keras.

1. INTRODUÇÃO

Sistemas de controle são uma parte fundamental da vida humana, pois estão presentes de diversas formas em suas vidas, seja na natureza, em aplicações tecnologicas e até mesmo como parte do funcionamento do corpo humano, em que tem-se uma saída dado a aplicação de uma entrada.

Com a evolução do conhecimento, viu-se que sistemas de controle podem ter aplicações diversas, podendo conter feedback para ajuste a fim de obter uma saída esperada.

Quando leva em consideração a visão de uma sistema que contem entrada e saída e possível que a informação sobre a dinamica interna desse sistema seja desconhecida, para isso é preciso utilizar a *Indentificação de Sistemas*.

As redes neurais artificiais surgiram como uma alternativa poderosa para essa tarefa devido a capaciadade de aprender padrões complexos através dos dados de entrada e saída. A utilização de uma rede neural artificial com um algoritmo de aprendizado torna essa tarefa possivel.

Este trabalho tem como objetivo implementar um rede ADALINE em conjunto com o algoritmo LMS (Least Mean Squares) para identificar um sistema dinamico linear de segunda ordem, que é variante no tempo, e aproximar esse sistema por um filtro adaptativo utilizando conceitos teoricos de controle e aprendizado de máquina.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 Sistemas Dinâmicos e Modelagem em Tempo Discreto

Um sistema dinâmico é formalmente definido como um sistema cujo estado evolui ao longo do tempo. A engenharia de controle busca modelar e manipular a relação entre a

entrada aplicada $u(t)$ e a saída resultante $y(t)$. Em controle digital, os sinais são amostrados em instantes discretos de tempo kT_{ab}, onde T_{ab} é o período de amostragem. Nesse domínio, a dinâmica do sistema é descrita por equações a diferenças, que relacionam a saída atual y(k) com entradas e saídas passadas.

Um sistema Linear e Invariante no Tempo (LIT) pode ser representado por uma equação a diferenças geral. Dependendo da sua estrutura, esses sistemas são classificados em duas categorias principais: IIR e FIR.

2.2 Filtros IIR e FIR

A distinção entre essas duas estruturas é fundamental para o nosso projeto.

Um sistema IIR (Infinite Impulse Response) é caracterizado pela presença de realimentação (*feedback*), ou seja, a saída atual $y(k)$ depende não apenas das entradas passadas, mas também das saídas passadas. Sua equação a diferenças tem a forma:

$$y(k) = \sum_{i=0}^{M} b_i u(k-i) - \sum_{j=1}^{N} a_j y(k-j) \tag{1}$$

A presença dos termos $y(kj)$ cria uma realimentação que faz com que a resposta a um impulso possa, teoricamente, ter duração infinita. As funções de transferência $G_1(s)$ e $G_2(s)$ do nosso projeto, por possuírem polos, são exemplos de sistemas IIR. A principal desvantagem de filtros IIR adaptativos é o risco de instabilidade, caso os polos do sistema se movam para fora do círculo unitário durante a adaptação.

Um sistema FIR (Finite Impulse Response), por outro lado, não possui realimentação. Sua saída é uma soma ponderada de um número finito de entradas passadas:

$$y(k) = \sum_{i=0}^{N-1} w_i u(k-i) \tag{2}$$

onde N é a ordem (ou o comprimento) do filtro. A resposta a um impulso de um filtro FIR tem sempre duração finita. Essa estrutura é incondicionalmente estável, o que a torna ideal para aplicações de filtragem adaptativa, justificando a escolha neste projeto de aproximar um sistema IIR por meio de um modelo FIR. A rede ADALINE, quando configurada com uma linha de atrasos na entrada, implementa exatamente um filtro FIR.

2.3 Identificação de Sistemas

A identificação de sistemas é o processo de construir um modelo matemático para um sistema dinâmico a partir de dados observados de sua entrada e saída. O objetivo é estimar os parâmetros do modelo (neste caso, os pesos w_i do filtro FIR) que melhor descrevem a relação entrada-saída.

Considerando um sistema que não há o conhcimento de sua dinamica, uma forma de avaliar o mesmo, é utilizar uma entrada que contenha zonas de possiveis excitações, pois o sistema irá reagir a algumas destas e assim sendo possivel avaliar a sua entrada e sáida.

Logo para que a identificação seja bem-sucedida, o sinal de entrada u(k) deve ser "suficientemente rico"para excitar todas as dinâmicas relevantes do sistema. Esse requisito é conhecido como persistência de excitaçã. Um sinal que não atende a essa condição pode levar a uma estimativa incorreta dos parâmetros do sistema. Sinais senoidais, por exemplo, excitam o sistema em apenas uma frequência. O ruído branco, por conter energia em todas as frequências, é um sinal ideal para excitação. No presente trabalho, foi utilizado um Sinal Binário Pseudo-Randômico (PRBS), que é uma aproximação prática e eficaz do ruído branco, garantindo a persistência de excitação necessária para a convergência do algoritmo adaptativo.

2.4 Filtros Adaptativos e o Neurônio ADALINE

Um filtro adaptativo é um sistema cujos parâmetros (os pesos do filtro) são ajustados automaticamente por um algoritmo de otimização. A estrutura básica de um filtro adaptativo consiste em dois componentes: um filtro digital (neste caso, FIR) e um algoritmo que ajusta os pesos desse filtro.

O ADALINE (Adaptive Linear Neuron), proposto por Widrow e Hoff, é a unidade de processamento fundamental que implementa um filtro FIR de forma elegante. Sua saída $\hat{y}(k)$ é o produto escalar entre o vetor de pesos $w(k)$ e o vetor de entrada $u(k)$, que contém as amostras atuais e passadas da entrada:

$$\hat{y}(k) = \sum_{i=0}^{N-1} w_i(k) u(k-i) = \mathbf{w}^T(k)\mathbf{u}(k) \tag{3}$$

O aprendizado é guiado pelo erro $e(k) = y(k)\hat{y}(k)$, onde $y(k)$ é a saida desejada (a saída do sistema IIR que queremos modelar).

2.5 O Algoritmo LMS (Least Mean Squares)

O algoritmo LMS é o coração do processo adaptativo, responsável por atualizar os pesos do filtro. Ele é uma implementaçao prática do método do gradiente descendente que busca minimizar a superficie de erro definida pelo Erro Quadrático Médio (MSE), $J = E[e^2(k)]$.

Em vez de calcular o gradiente verdadeiro, o que exigiria conhecimento estatístico do sinal, o LMS utiliza uma estimativa instantânea do gradiente, $\nabla J \approx \nabla e^2(k) = 2e(k)u(k)$. Isso leva a uma regra de atualização simples e computacionalmente muito eficiente:

$$\mathbf{w}(k+1) = \mathbf{w}(k) - \frac{1}{2}\mu\nabla e^2(k) = \mathbf{w}(k) + \mu e(k)\mathbf{u}(k) \tag{4}$$

O parâmetro μ, conhecido como taxa de aprendizado, controla a velocidade de convergência e a estabilidade do algoritmo. Um valor de μ muito pequeno leva a uma convergência lenta, enquanto um valor muito grande pode levar à instabilidade e divergência dos pesos.

2.6 Sistemas Variantes no Tempo e a Solução de Wiener

Este projeto aborda a identificação de um sistema variante no tempo, ou não-estacionário, cuja dinâmica muda em t=80s. Este é um cenário onde a superioridade dos filtros adaptativos se torna evidente.

Para um sistema LIT (invariante no tempo), existe uma solução ótima e analítica para os pesos do filtro, conhecida como solução de Wiener, que minimiza o MSE globalmente. Essa solução é dada por $w_o = R^-1 \cdot p$, onde R é a matriz de correlação da entrada e p é o vetor de correlação cruzada entre a entrada e a saída desejada. O método newlind (ou a pseudo-inversa) implementado no projeto é uma forma de calcular essa solução de Wiener para todo o conjunto de dados de uma só vez.

No entanto, para um sistema variante no tempo, não existe uma única solução de Wiener que seja ótima para todo o tempo. A solução calculada em batelada (newlind) encontrará apenas um modelo "médio", que não é preciso nem antes nem depois da mudança. O algoritmo LMS, por outro lado, por ser iterativo e "esquecer"o passado gradualmente, tem a capacidade de rastrear as mudanças na dinâmica do sistema, convergindo para uma nova solução ótima após a mudança na planta.

3. METODOLOGIA DO PROJETO

O projeto foi implementado em Python, na versão 3.11.7,na qual foi utilizado o aplicativo VS Code para a codificação, sendo um ambiente de computação interativo (*Jupyter Notebook*). Foram utilizadas as bibliotecas NumPy para operações numéricas, SciPy para funções de controle e processamento de sinais, Matplotlib para a visualização dos resultados e csv para importação de dados.

Segue-se então para o procedimento experimental para a identificação do sistema dinâmico variante no tempo utilizando a rede ADALINE.

3.1 Modelagem e Discretização da Planta

O sistema possui uma mudança no seu regime de operação, mas especificamente, a sua função de transferencia muda em determinado momento. Portanto, define-se duas funções de transferência contínuas que descrevem o sistema em seus diferentes regimes de operação:

- $G_1(s) = \dfrac{1}{s^2 + 0.2s + 1}$ para $0 \leq t < 80$ s
- $G_2(s) = \dfrac{3}{s^2 + 2s + 1}$ para $t \geq 80$ s

Como deseja-se analisar esse sistema computacionalmente, precisa-se discretizar as funções, dado a natureza do algoritmo LMS. Logo, ambas funções de transferências foram discretizadas utilizando a função **signal.cont2discrete** da biblioteca **scipy**, com um período de amostragem $T_{ab} = 0.1$ s e o método do Retentor de Ordem Zero (ZOH), gerando os modelos equivalentes em tempo discreto.

3.2 Geração do Sinal de Excitação

Como é sabido, precisa-se uma entrada que contenha um sinal rico, ou em outras palavras, um sinal que consiga excitar todas as dinâmicas do sistema, um ruído branco seria o ideal. Foi utilizado um Sinal Binário Pseudo-Randômico (PRBS), que é uma aproximação do ruído branco e para isso foi utilizado uma planilha de valores que estão dispostos em 2 colunas para serem utilizados em 2 valores diferentes de banda, sendo $0,01$ e $0,05$. Esse valores variam de x a y e estão no arquivo **idinp.csv**, que foi adicionado a mesma pasta do codigo para ter acesso a este arquivo.

3.3 Geração da Resposta do Sistema

A resposta do sistema variante no tempo, y(k), que serve como sinal alvo para o treinamento da rede, foi gerada em duas etapas. Primeiro, $G_1(s)$ foi simulado para os primeiros 80 segundos. Em seguida, $G_2(s)$ foi simulado para o restante do tempo, utilizando o estado final da primeira simulação como condição inicial. Para isso utiliza-se a função **signal.lsim** que fornerá a saída discretizada, função está que é crucial para garantir a continuidade e a representação fiel de um sistema cuja dinâmica muda abruptamente.

3.4 Implementação do Filtro Adaptativo ADALINE-LMS

O núcleo da identificação adaptativa foi a implementação de uma função para a rede ADALINE, que opera como um filtro FIR. A função foi projetada para operar em dois modos:

(1) **Modo Adaptativo:** Os pesos sinápticos do filtro são inicializados com zero e atualizados a cada amostra de tempo k de acordo com a regra de atualização do algoritmo LMS: $w(k+1) = w(k) + \mu \cdot e(k) \cdot u(k)$.
(2) **Modo de Simulação:** Os pesos são mantidos fixos para simular a resposta do filtro com um conjunto de coeficientes pré-definido.

3.5 Implementação da Solução por Mínimos Quadrados (Newlind)

Como contraponto à abordagem adaptativa, foi implementada a solução ótima em batelada, equivalente ao método newlind. Para isso, foi construída a matriz de regressores U, onde cada coluna representa uma versão atrasada do sinal de entrada u(k). Os pesos ótimos w_d foram então calculados de uma só vez por meio da solução da equação normal (*Newlind*/pseudo-inversa), que minimiza o erro quadrático médio sobre todo o conjunto de dados.

3.6 Execução do Experimento e Análise Comparativa

O experimento foi conduzido executando as três abordagens:

- A rede ADALINE em modo adaptativo para gerar a saída $y_a(k)$.
- A solução newlind para gerar a saída $y_d(k)$.
- A rede ADALINE com os pesos finais do treinamento adaptativo para gerar a saída $y_f(k)$.

Os resultados foram então plotados em um gráfico para uma análise visual comparativa com a resposta real dos sistema, e assim verificar a capacidade de cada método em rastrear a saída do sistema variante no tempo.

3.7 Metaparametros n e lr (ou μ)

Um grande desafio de uma implementação de uma RNA é a determinação dos metaparametros, e estes foram pré

definidos incialmente para obter um resultado a ser analisado. O metaparametro n é o delay e o lr/μ é a taxa de aprendizado, que nesse caso foram inicialmente determinados como $n = 4$ e $\mu = 0.4$ e para isso o valor de banda sendo 0 - 0.01.

Uma mudança dos valores de n e lr pode trazer uma boa melhoria para os resultados, então foi implementado um algoritmo que traz os valores dos erros quadrático médios (MSE) para a rede ADALINE e através deste, pôde-se determinar o menor MSE. Assim, o valores que de n e lr podem ser substituído para obter uma melhor resposta. Para possiveis valores de n escolheu arbitrariamente um vetor de numeros inteiros no intervalo de 1 a 100, com saltos de uma unidade e para μ os valores no intevalo de 0.1 a 0.99, com intervalo de 0.01, depois o mesmo intervalo para n, porém para μ um invervalo de 0.01 a 0.2 com 100 elementos. Com isso, alterou-se os valores de n e lr e realizado o teste com a banda 0 - 0.05.

Para a geração de graficos e imagens foi otilizado a biblioteca matplotlib, que permitiu gerar os graficos das respostas e também dos erro para cada metodo, como será visto na próxima seção.

4. RESULTADOS E DISCUSSÃO

Com a determinação incial da banda como 0 - 0.0.1, n = 4 e $\mu = 0.4$ (mesmo que μ ou **lr**), a execução do codigo produziu resultados a serem avaliados detalhadamente, avaliando a capacidade de cada método em modelar um sistema variante no tempo.

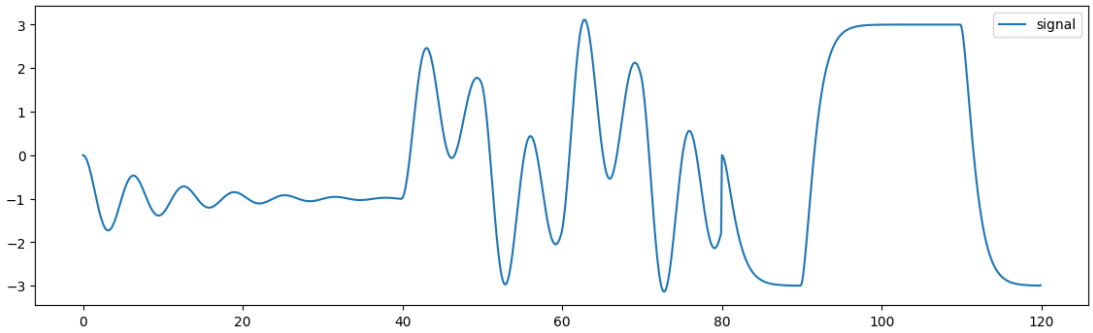


Figura 1: Resposta real do sistema para a banda 0 - 0.01

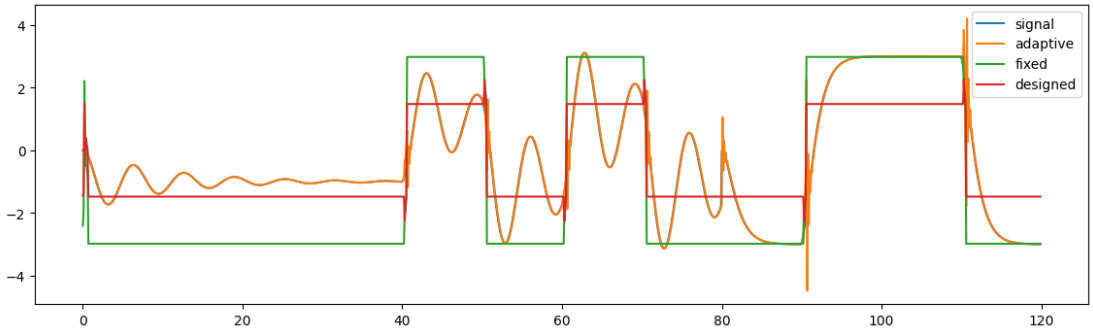


Figura 2: Respostas obtidas a partir dos metodos para a modelagem do sistema para a banda 0 - 0.01.

A partir disso com a execução do algoritmo para determinar o valores ideias de n e μ, verificou-se que o valores ideias seriam n = 9 e $\mu = 0.16$, esse valores dão como resultado o $MSE =$ para a banda 0 - 0.01.

Fazendo a execução completa do codigo, porém alterando os novos valores de n, μ e alterando a banda para 0 - 0.05, pois contém um padrão um pouco mais complexo que a banda anterior, gerou os resultados mostrados nas **Figura [3]** e **Figura [4]**

O *MSE* encontrado para a banda 0 - 0.05 com $n = 9$ e $\mu = 0.16$ foi de 0.3140856128403408. Para validar, foi executado o algoritmo que estima os melhores valores para os hiperparametros atevés do menor *MSE*, nesse caso foi a melhor configuração encontrada foi delays $n = 11$, $\mu = 0.084848$, com o menor MSE obtido sendo 0.17692316067699101. Alterando esse novos valores dos metaparametros, obtém-se os resultados mostrados nas **Figura [5]** e **Figura [6]**.

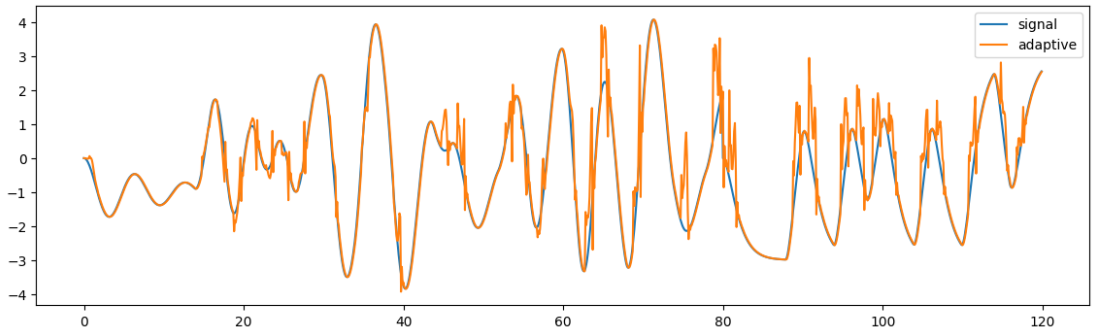


Figura 3. Resposta real do sistema junto com a Resposta adaptativa para a banda 0 - 0.05, com $n = 9$ e $\mu = 0.16$.

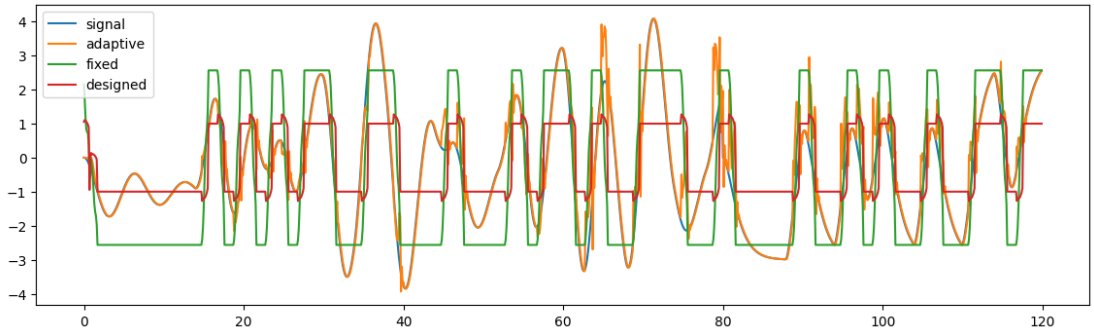


Figura 4. Respostas obtidas a partir dos metodos para a modelagem do sistema para a banda 0 - 0.05, com $n = 9$ e $\mu = 0.16$.

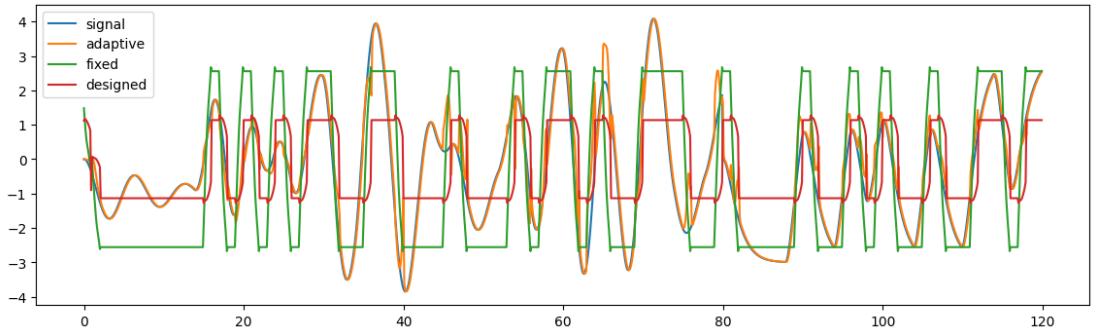


Figura 5. Resposta real do sistema junto com a Resposta adaptativa para a banda 0 - 0.05, com $n = 11$ e $\mu = 0.084848$.

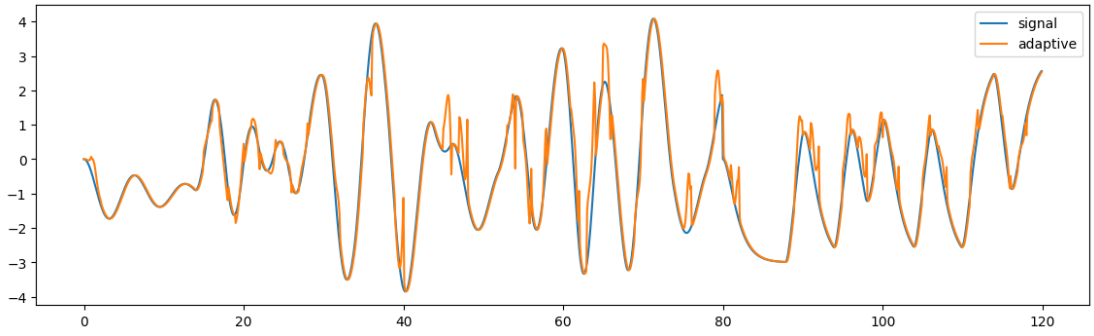


Figura 6. Respostas obtidas a partir dos metodos para a modelagem do sistema para a banda 0 - 0.05, com $n = 11$ e $\mu = 0.084848$.

4.1 Análise do Rastreamento do Sistema Variante no Tempo

Como resultado obteve-se os graficos que contém a saída real do sistema (curva "Sistema Real (Alvo)"), a saída do filtro ADALINE treinado adaptativamente (curva "Adaline Adaptativo") e a saída do filtro com pesos calculados pela solução de Mínimos Quadrados (curva "Newlind").

Ao analisar os graficos obtidos que representam a saida real e a reposta dos metodos de modelagem para cada valores de banda utilizado, obtém um um panorama detalhado da capacidade de modelagem de cada metodo.

Comparando as **Figura [1]** e **Figura [3]** é possivel ver a maior complexidade da saída real do sistema a depender da banda utilizada.

Então, considerando as **Figura [2]**, **Figura [4]** e **Figura [6]**, os resultado obtido, tem-se que a saída do filtro adaptativo demonstra uma notável capacidade de rastreamento do sinal real durante todo o período da simulação, que pode ser visto ao compararar a curva laranjada das respostas com suas respectivas saída real, isso fica mais evidente nas **Figura [3]** e **Figura [5]**, sobrepoem a curva da saida real com a saida do metodo adapativo.

Antes do instante t=80s, o modelo converge e acompanha a dinâmica do sistema $G_1(s)$. Após a mudança abrupta na planta, o modelo rapidamente se readapta e passa a seguir com precisão a nova dinâmica do sistema $G_2(s)$. Este resultado valida experimentalmente a principal vantagem dos algoritmos adaptativos, como o LMS, em ambientes não-estacionários, conforme discutido na Fundamentação Teórica.

Diferentemente, a saída projetada pelo método de Newlind (curva vermelha) não consegue modelar o sistema de forma satisfatória. Como previsto na teoria, este método encontra uma solução de Wiener "média", que representa um compromisso que não é ótimo para nenhum dos dois regimes de operação. Fica evidente que, após t=80s, o modelo falha completamente em capturar a amplitude e a dinâmica do sistema após deter a dinamica $G_2(s)$. Isso ilustra a limitação fundamental de métodos em batelada para a identificação de sistemas variantes no tempo.

A curva 'fixed' (verde) oferece uma visão interessante. Ela utiliza os pesos finais obtidos pelo algoritmo adaptativo. Como esses pesos foram otimizados para a segunda parte da simulação (após t=80s), o desempenho desta curva é muito ruim na primeira metade e melhora consideravelmente na segunda, onde se aproxima da performance do modelo adaptativo. Isso reforça a ideia de que um conjunto de pesos só é "ótimo"para a dinâmica específica para a qual foi treinado.

4.2 Análise do Erro (e = Saida Real - Saida do Filtro)

A forma mais efetiva de verificar a consistencia e eficiencia dos resultados, comentanda anterirormente, é avaliar o comportamento do erro para metodo utilizado, pois assim tem-se uma justificativa quantitativa do melhor metodo. Levando em consideração $n = 11$ e $\mu = 0.084848$, tem se os seguintes resultados mostrados nas **Figura [7]**, **Figura [8]** e **Figura [9]**.

Analisando a **Figura [7]**, ver-se que a amplitude do erro está aproximadamente entre 2 e -2 para os piores casos, porém é notorio que os casos com erros mais elevados, acima de 1, são bem menores que os erros mais proximo de zero.

Para as **Figura [8]** e **Figura [9]** ver-se que além de possui amplitude geral maior que para o filtro adaptivo da **Figura [7]** e a ocorrencia de erros de valore elevados é muito frequente.

Isso mostra o sistema *newlind* e com pesos fixo tiveram muito problema para conseguir mapear a saida do sistema real. O erro foi muito grotesco e isso foi visto nas imagens de resultados, e agora portanto, comprovando através dos graficos de erro quão superior é o sistema adaptive que foi utilizado o *ADALINE.*

O filtro ADALINE-LMS foi o único capaz de identificar e rastrear com precisão a dinâmica de um sistema que muda suas características ao longo do tempo. As abordagens baseadas em filtros com coeficientes fixos, por outro lado, mostraram-se insuficientes para a tarefa, validando os conceitos teóricos de filtragem adaptativa apresentados.

Os resultados experimentais validam de forma conclusiva a teoria apresentada. A comparação direta entre as saídas dos filtros e a análise detalhada do sinal de erro demonstram que a abordagem adaptativa com a rede ADALINE e o algoritmo LMS é uma ferramenta eficaz e robusta para a identificação e o rastreamento de sistemas lineares variantes no tempo, cumprindo com sucesso todos os objetivos propostos para este trabalho.

5. CONCLUSÃO

Este trabalho teve como objetivo principal demonstrar a eficácia de um filtro adaptativo, implementado com uma rede neural ADALINE e o algoritmo LMS, na identificação de um sistema dinâmico linear variante no tempo. A abordagem consistiu em aproximar a resposta de um sistema IIR, cuja dinâmica mudava abruptamente, por meio de um modelo FIR adaptativo, validando conceitos fundamentais de controle inteligente e processamento de sinais.

Os resultados experimentais confirmaram de forma inequívoca a superioridade da abordagem adaptativa. A análise comparativa mostrou que o filtro ADALINE-LMS foi capaz de rastrear com alta fidelidade a saída do sistema em ambos os regimes de operação, adaptando-se rapidamente à mudança em sua dinâmica. Em contrapartida, a solução em batelada (Mínimos Quadrados) falhou em modelar o sistema, gerando um modelo "médio"impreciso e incapaz de reagir à não-estacionariedade. A análise do sinal de erro corroborou esses achados, exibindo um pico pronunciado no momento da mudança, seguido por uma rápida convergência, o que ilustra visualmente o mecanismo de correção do algoritmo LMS.

Conclui-se, portanto, que a metodologia empregada foi bem-sucedida em cumprir todos os objetivos propostos. Foi demonstrado, tanto na teoria quanto na prática, que para sistemas cujas características mudam ao longo do tempo — um cenário comum em aplicações de mecatrônica e controle do mundo real — os algoritmos adaptativos online não são apenas uma alternativa, mas uma necessidade. A simplicidade e a robustez do conjunto ADALINE-LMS provaram ser uma ferramenta poderosa e eficiente para tarefas de identificação de sistemas em ambientes não-estacionários.

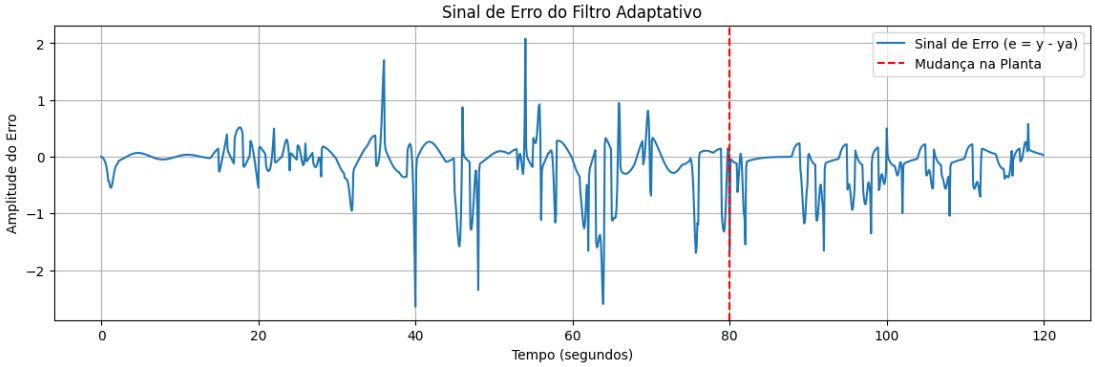


Figura 7. Grafico do erro para o filtro Adaline com metaparametros n = 11 e $\mu = 0.084848$.

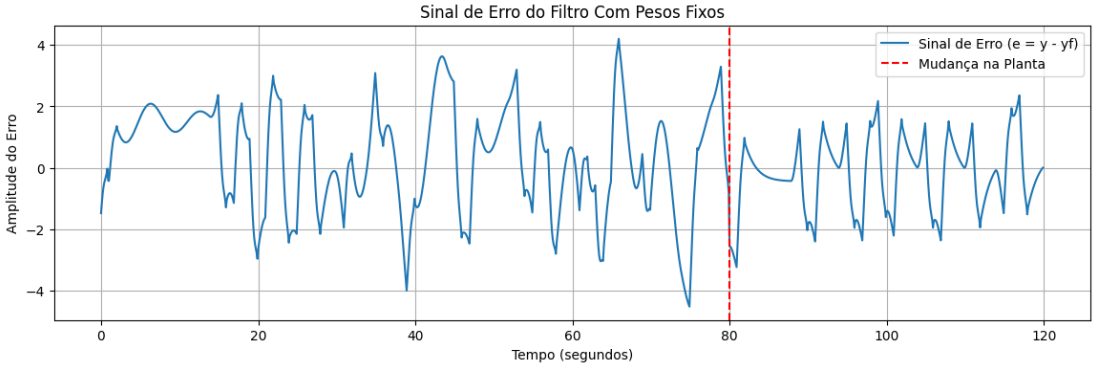


Figura 8. Grafico do erro para o filtro Com pesos fixos com metaparametros n = 11 e $\mu = 0.084848$.

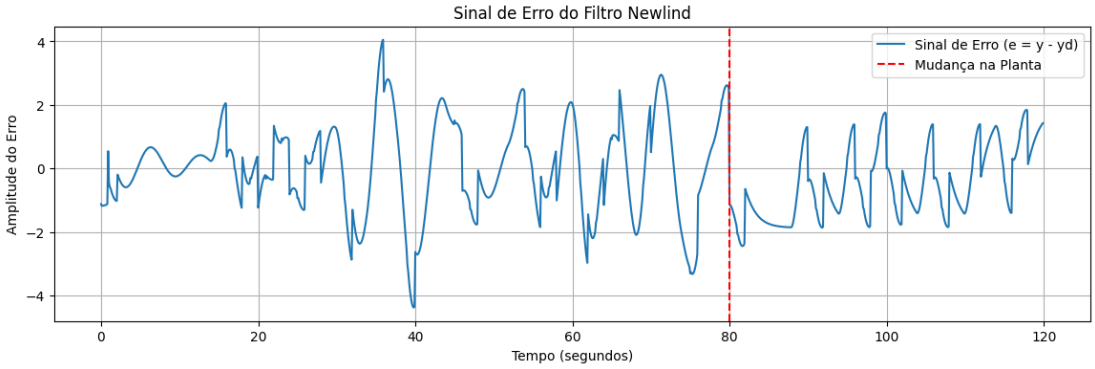


Figura 9. Grafico do erro para o filtro Newlind com metaparametros n = 11 e $\mu = 0.084848$.

REFERÊNCIAS

Silva, I.N.; Spatti, D. H.; Flauzino, R. A.: Redes Neurais Artificiais - para Engenharia e Ciências Aplicadas, Artliber, 2016

Goodfelow, I., Bengio, Y., Courville, A. Deep Learning, MIT Press, 2016

Murphy, Kevin P.: Probabilistic Machine Learning: An Introduction, MIT Press, 2022

HAYKIN, S. (2009). Neural Networks and Learning Machines (3rd ed.). Pearson Prentice Hall.

SILVA, I. N. da; SPATTI, D. H.; FLAUZINO, R. A. (2016). Redes Neurais Artificiais para Engenharia e Ciências Aplicadas (2a ed.). Artliber.

Ogata, Katsuhiko Engenharia de controle moderno / Katsuhiko Ogata ; tradutora Heloísa Coimbra de Souza ; revisor técnico Eduardo Aoun Tannuri. – 5. ed. – São Paulo : Pearson Prentice Hall, 2010.

Nise, Norman S. Engenharia de sistemas de controle / Norman S. Nise; tradução e revisão técnica Jackson Paul Matsuura. - 6. ed. - [Reimpr.]. - Rio de Janeiro: LTC, 2013.

https://www.ene.unb.br/adolfo/Lectures/IC.html